

Predicción de la Calidad del Café Arábica mediante Machine Learning a partir de Metadatos Agrícolas

Guillermo Mejía Uribe
Universidad de Antioquia
Medellín, Colombia
guillermo.mejia@udea.edu.co

Víctor Restrepo
Universidad de Antioquia
Medellín, Colombia
vmanuel.restrepo@udea.edu.co

Daniel Duque Rivera
Universidad de Antioquia
Medellín, Colombia
daniel.duquer@udea.edu.co

Resumen—La evaluación sensorial del café de especialidad requiere catadores certificados (Q Graders), un proceso costoso y subjetivo. Este trabajo explora si es posible estimar el puntaje total de catación (Total Cup Points) del café Arábica utilizando únicamente metadatos agrícolas (país de origen, altitud, método de procesamiento, defectos y humedad), descartando variables sensoriales no disponibles antes de la catación. Se evaluaron seis modelos de regresión sobre 1310 muestras del Coffee Quality Institute, empleando validación cruzada anidada e intervalos de confianza bootstrap. El mejor modelo (Random Forest) alcanzó un RMSE de 2.426 puntos (IC95 %: [2.177, 2.741]) y R^2 de 0.187, con desempeño consistente en prueba (RMSE=2.312, R^2 =0.207). El error en cafés de baja calidad (<80 pts) es 2.87 veces mayor que en cafés de especialidad (RMSE=4.983 vs 1.735). PCA redujo la dimensionalidad de 48 a 10 componentes (79.2 % de compresión) con degradación mínima (Δ RMSE=+0.105). El análisis de importancia reveló que el país de origen es el predictor más relevante. Aunque la predicción exacta es limitada, el modelo clasifica correctamente el 87.2 % de los cafés y ofrece una herramienta de orientación útil, metodológicamente honesta e interpretable para pequeños productores.

I. INTRODUCCIÓN

El café de especialidad se define por alcanzar un puntaje de 80 o más puntos sobre 100 en la escala del Coffee Quality Institute (CQI). Para obtener esta certificación, el café debe ser evaluado por al menos tres catadores certificados, conocidos como Q Graders, quienes asignan puntuaciones a atributos sensoriales como aroma, sabor, acidez, cuerpo y balance. Este proceso, aunque riguroso, presenta problemas significativos: (i) **subjetividad**: diferentes catadores pueden asignar puntuaciones distintas al mismo café; (ii) **alto costo**: montar un laboratorio de catación y pagar a múltiples expertos representa un gasto que muchos pequeños productores no pueden asumir; y (iii) **falta de escalabilidad**: no es posible catar cada lote de café producido en el mundo.

Por estas razones, surge la pregunta: ¿es posible utilizar datos históricos y técnicas de aprendizaje automático para estimar la calidad del café sin necesidad de una catación completa? Este trabajo aborda esta pregunta con un enfoque metodológicamente riguroso: predecir el puntaje total únicamente a partir de metadatos agrícolas (país de origen, altitud, método de procesamiento, defectos visibles y humedad), datos que el productor conoce *antes* de decidir si paga una catación oficial.

Se utilizó la base de datos pública del CQI, que contiene 1310 muestras de café de la especie Arábica tras un proceso de limpieza. A diferencia de trabajos previos que incluyen variables sensoriales como predictores (lo que constituye una fuga de información metodológica), este proyecto se enfoca exclusivamente en metadatos agrícolas. El objetivo no es reemplazar a los catadores, sino ofrecer una herramienta de bajo costo, respuesta rápida y explicable para los productores.

II. DESCRIPCIÓN DEL PROBLEMA

II-A. Contexto y utilidad

El café de especialidad representa un mercado en crecimiento con márgenes significativamente mayores que el café commodity. Sin embargo, el acceso a este mercado está condicionado por la obtención de un puntaje ≥ 80 puntos, lo que requiere una catación oficial. Para un pequeño productor, el costo de enviar muestras a un laboratorio y pagar a los catadores puede representar semanas o meses de ingresos. Una herramienta de estimación de calidad basada en datos agrícolas permitiría filtrar lotes prometedores, identificar factores de mejora y fortalecer la posición en negociaciones.

II-B. Composición de la base de datos

El dataset original del CQI contenía 1311 muestras de café Arábica y 44 variables. Tras eliminar una muestra atípica con puntaje total igual a cero, se trabajó con 1310 muestras. Se seleccionaron 8 variables agrícolas como características de entrada:

- **Country.of.Origin** (categórica): país de cultivo.
- **Processing.Method** (categórica): lavado (washed), natural (dry) o honey.
- **Color** (categórica): color del grano verde (Green, Bluish-Green, etc.).
- **altitude_mean_meters** (numérica): altitud media en metros.
- **Category.One.Defects** (numérica): defectos primarios (granos negros, agrios, etc.).
- **Category.Two.Defects** (numérica): defectos secundarios (cascarilla, granos partidos).
- **Number.of.Bags** (numérica): tamaño del lote en sacos.
- **Moisture** (numérica): porcentaje de humedad del grano verde.

La variable objetivo es *Total.Cup.Points*, un valor continuo entre 59.83 y 90.58 puntos.

II-C. Análisis exploratorio

II-C1. Distribución y estrategia de compensación de sesgo: El 86.3 % de las muestras superan el umbral de especialidad de 80 puntos. Este fuerte sesgo implica que un modelo ingenuo que siempre prediga “café de especialidad” tendría una precisión del 86.3 % sin aprender nada útil. Para compensar esto, se implementó una estrategia de **pesos de muestra inversamente proporcionales a la densidad del target**. Usando estimación de densidad por kernel (KDE), se asignó a cada muestra un peso $w_i = 1/\hat{f}(y_i)$, donde $\hat{f}(y_i)$ es la densidad estimada en su puntaje. Como resultado, los cafés de baja calidad (¡80 pts) recibieron un peso promedio 9.1 veces mayor que los de especialidad, asegurando que los errores en la zona minoritaria sean penalizados más fuertemente durante el entrenamiento.

La Figura 1 ilustra esta distribución. Se observa una concentración de muestras en el rango de 80 a 85 puntos, mientras que la cola izquierda (puntuajes menores a 80) es escasa, confirmando el desbalanceo del dataset.




Figura 1. Distribución de la variable objetivo Total Cup Points. La línea roja marca el umbral de especialidad (80 puntos). El 86.3 % de las muestras superan este umbral.

II-C2. Valores faltantes: Se identificaron valores faltantes en *Processing.Method* (11.6 %), *Color* (20.4 %) y *altitude_mean_meters* (17.3 %). La estrategia de imputación fue: mediana para numéricas, moda para categóricas.

II-C3. Relaciones entre variables: La Figura 2 muestra las matrices de correlación de Pearson y Spearman para todas las variables numéricas. Además de confirmar las relaciones con el puntaje total (que se analizan en detalle en la Figura 6), estas matrices permiten identificar posibles problemas de colinealidad entre variables predictoras. No se detectó ninguna correlación superior a 0.85 entre pares de variables, por lo que todas fueron retenidas para el análisis.




Figura 2. Matrices de correlación: Pearson (izquierda) y Spearman (derecha). La altitud y los defectos secundarios muestran las relaciones más fuertes con el puntaje total.

La Figura 3 explora dos relaciones adicionales de gran interés. En el panel izquierdo se observa la relación entre la altitud media de cultivo y el puntaje total. Aunque la correlación lineal es baja ($r=0.162$), la tendencia positiva confirma la hipótesis agronómica de que cafés cultivados a mayor altitud tienden a obtener mejores puntuaciones. En el panel derecho se presentan los 10 países con mayor puntaje promedio (considerando solo aquellos con al menos 10 muestras). Etiopía, Colombia y Kenia lideran la lista, lo cual explica por qué el país de origen resulta ser el predictor más importante en el modelo Random Forest (como se verá en la Sección VII). Este análisis también sugiere que el origen captura factores no medidos directamente en el dataset, como condiciones climáticas, tipo de suelo o tradiciones de cultivo.




Figura 3. Izquierda: relación entre altitud y puntaje total. Derecha: top 10 países con mayor puntaje promedio.

II-D. Limitaciones del dataset

Es fundamental reconocer las limitaciones: (i) pocas variables agrícolas disponibles, (ii) fuerte sesgo hacia cafés de alta calidad (solo 13.7 % con puntaje ¡80), (iii) datos recolectados entre 2010-2018, y (iv) valores faltantes no despreciables.

III. ESTADO DEL ARTE

Se identificaron tres trabajos previos con el mismo dataset. La Tabla I resume sus características y limitaciones.

Tabla I
TRABAJOS PREVIOS CON EL DATASET CQI.

Autor (año)	Modelos	Métrica principal	Limitación
Merton Chen (2022)	Random Forest	Accuracy 96.5 %	Usó variables sensoriales (fuga de información)
UBC MDS Team (2021)	Ridge, RF	AUC-ROC 0.67	Resultado apenas superior al azar
Methmi Melewee (2023)	SVR, GBM, RF	RMSE, MAE, R ²	Modelo caja negra, sin explicabilidad

Ninguno de los trabajos previos se enfocó exclusivamente en datos agrícolas para regresión del puntaje exacto. Este

proyecto aporta honestidad metodológica, evaluación de modelos no probados antes (MLP, SVR con grilla optimizada), explicabilidad mediante importancia de variables, y evaluación segmentada por calidad.

IV. METODOLOGÍA EXPERIMENTAL

IV-A. Preprocesamiento

Se construyó un pipeline con imputación (mediana para numéricas, moda para categóricas), estandarización Z-score y one-hot encoding. Tras la codificación, la dimensionalidad efectiva fue de 48 variables.

IV-B. División de datos

Se reservó el 15 % como conjunto de prueba (197 muestras) y el 85 % restante (1113 muestras) para entrenamiento y validación cruzada.

IV-C. Validación cruzada anidada

Para obtener estimaciones de desempeño sin sesgo, se empleó validación cruzada anidada: bucle interno de 3 folds para búsqueda de hiperparámetros (GridSearchCV) y bucle externo de 5 folds para estimación de desempeño. Intervalos de confianza del 95 % calculados mediante bootstrapping (200 remuestreos). Métricas: RMSE, MAE y R^2 .

IV-D. Modelos e hiperparámetros

Se evaluaron seis modelos: Ridge (paramétrico), KNN (no paramétrico), Random Forest (ensemble), Gradient Boosting (ensemble), MLP (red neuronal) y SVR. La Tabla II muestra la malla de hiperparámetros.

Tabla II
HIPERPARÁMETROS EVALUADOS POR MODELO.

Modelo	Hiperparámetro	Malla de valores
Ridge	alpha	[0.01, 0.1, 1, 10, 100, 1000]
KNN	n_neighbors	[3, 5, 7, 10, 15, 20]
KNN	weights	[uniform, distance]
Random Forest	n_estimators	[100, 200]
Random Forest	max_depth	[None, 10, 20]
Random Forest	min_samples_leaf	[1, 3, 5]
Gradient Boosting	n_estimators	[100, 200]
Gradient Boosting	learning_rate	[0.05, 0.1, 0.2]
Gradient Boosting	max_depth	[3, 5]
MLP	hidden_layer_sizes	[(50,), (100,), (100,50), (100,100)]
MLP	alpha (L2)	[0.0001, 0.001, 0.01]
SVR	kernel	[linear, rbf]
SVR	C	[0.01, 0.1, 1, 10, 20]
SVR	gamma	[scale, auto, 0.01, 0.1]

V. RESULTADOS

V-A. Comparativa de modelos

La Tabla III presenta los resultados de validación cruzada. Random Forest fue el mejor (RMSE=2.426, R^2 =0.187), seguido por Gradient Boosting y Ridge. MLP tuvo desempeño muy pobre (R^2 negativo), indicando que una red neuronal simple no es adecuada para este problema con los datos disponibles.

Tabla III
RESULTADOS DE VALIDACIÓN CRUZADA 5-FOLD CON IC BOOTSTRAP 95 %.

Modelo	RMSE Val	IC 95 % RMSE	MAE Val	R^2 Val
Random Forest	2.426	[2.177, 2.741]	1.640	0.187
Gradient Boosting	2.439	[2.173, 2.754]	1.642	0.179
Ridge	2.447	[2.199, 2.669]	1.672	0.168
SVR	2.480	[2.196, 2.764]	1.619	0.149
KNN	2.578	[2.424, 2.817]	1.721	0.072
MLP	3.812	[3.326, 4.502]	2.314	-1.025

La Figura 4 complementa esta tabla mostrando visualmente las diferencias entre modelos. En el panel izquierdo se observa que Random Forest, Gradient Boosting y Ridge presentan los RMSE más bajos, con intervalos de confianza que se solapan, lo que indica que sus desempeños son estadísticamente similares. En el panel derecho, el R^2 de estos tres modelos es positivo (0.15-0.19), mientras que MLP presenta un R^2 negativo, confirmando su mal desempeño.




Figura 4. Comparación de RMSE (izquierda) y R^2 (derecha) con intervalos de confianza al 95 %. Random Forest presenta el menor RMSE.

V-B. Desempeño en test

El mejor modelo (Random Forest) se reentrenó con sus mejores hiperparámetros (max_depth = 20, min_samples_leaf = 5, n_estimators = 100) y se evaluó sobre el conjunto de prueba: RMSE=2.312, MAE=1.673, R^2 =0.207, valores consistentes con la validación cruzada.

V-C. Evaluación segmentada por calidad

La Tabla IV muestra el RMSE segmentado. El hallazgo más relevante es que el error en cafés de baja calidad es aproximadamente 3 veces mayor que en cafés de especialidad. Para Random Forest, el RMSE en cafés <80 pts es 4.983 puntos, mientras que en cafés ≥80 pts es solo 1.735 puntos.

Tabla IV
RMSE SEGMENTADO POR CALIDAD (PREDICCIONES OUT-OF-FOLD).

Modelo	RMSE Global	RMSE (≥80, n=961)	RMSE (<80, n=152)	Ratio
Random Forest	2.448	1.735	4.983	2.87x
Gradient Boosting	2.464	1.696	5.125	3.02x
Ridge	2.462	1.689	5.131	3.04x
SVR	2.502	1.592	5.458	3.43x

La Figura 5 muestra la matriz de confusión para la clasificación binaria de especialidad. Se observa que el modelo identifica correctamente 939 de los 961 cafés de especialidad (verdaderos positivos), con solo 22 falsos negativos.

Sin embargo, hay 121 falsos positivos (café de baja calidad clasificados como especialidad), lo que indica una tendencia a sobreestimar la calidad en la zona minoritaria.

Fig. 6 — Matriz de Confusión (umbral 80 pts)
Random Forest (ensemble)




Figura 5. Matriz de confusión para clasificación de especialidad (umbral 80 pts). Precisión del 87.2 %, con 939 verdaderos positivos y 22 falsos negativos.

V-D. Curvas de validación y aprendizaje

Las curvas de validación permiten analizar cómo varía el desempeño de cada modelo al modificar su hiperparámetro principal, identificando posibles problemas de sobreajuste o subajuste. La Figura 6 muestra estas curvas para los seis modelos evaluados.

Para Ridge, el RMSE de validación disminuye rápidamente al aumentar alpha hasta 1, estabilizándose después, lo que indica que valores muy altos de regularización no aportan beneficios adicionales. En el caso de Random Forest, el RMSE de validación mejora al aumentar el número de árboles hasta 100, mostrando que conjuntos más grandes no mejoran significativamente el desempeño. Para SVR, la curva con respecto al parámetro C muestra que valores entre 1 y 10 producen los mejores resultados, mientras que valores muy bajos (0.1) o muy altos (1000) degradan el desempeño.




Figura 6. Curvas de validación para los seis modelos evaluados. Cada subgráfica muestra la evolución del RMSE en entrenamiento y validación al modificar el hiperparámetro principal.

La Figura 7 presenta la curva de aprendizaje del mejor modelo (Random Forest). Se observa que el RMSE de

entrenamiento es bajo (cercano a 1.9) mientras que el de validación se estabiliza alrededor de 2.4 puntos. La brecha entre ambas curvas indica un cierto sobreajuste, aunque no es extremo. Las curvas convergen a medida que aumenta el tamaño del conjunto de entrenamiento, lo que sugiere que añadir más datos no mejoraría significativamente el desempeño del modelo.

Fig. 11 — Curva de Aprendizaje — Random Forest (ensemble)




Figura 7. Curva de aprendizaje de Random Forest: evolución del RMSE en entrenamiento y validación al aumentar el tamaño del conjunto de entrenamiento.

VI. REDUCCIÓN DE DIMENSIONALIDAD

VI-A. Análisis individual de variables numéricas

La Figura 8 muestra las correlaciones de las variables numéricas exclusivamente con el puntaje total, utilizando los coeficientes de Pearson (relaciones lineales) y Spearman (relaciones monótonas). Se observa que la altitud presenta una correlación de Spearman positiva de 0.253, confirmando la hipótesis agronómica de que mayores altitudes se asocian con mejor calidad. Los defectos secundarios (Category.Two.Defects) muestran la correlación negativa más fuerte en Pearson (-0.287), indicando que a mayor número de defectos, menor puntaje.

Siguiendo la regla de retención establecida ($|r| \geq 0.05$) en al menos uno de los dos coeficientes, todas las variables numéricas superan este umbral. La variable Number.of.Bags, aunque presenta la correlación más baja (Pearson=0.036, Spearman=0.066), supera el umbral gracias a su correlación Spearman. Por lo tanto, ninguna variable numérica fue eliminada por baja correlación con el target.

Adicionalmente, no se detectó colinealidad alta ($|r| \geq 0.85$) entre pares de variables predictoras (este análisis se realizó sobre la matriz completa de correlación de la Figura 2). Esto indica que, desde el punto de vista del análisis individual, no hay una justificación clara para reducir la dimensionalidad eliminando variables numéricas. Sin embargo, técnicas de extracción de características como PCA podrían lograr una compresión efectiva al combinar información de múltiples variables.




Figura 8. Correlación de variables numéricas con Total Cup Points: Pearson y Spearman. La altitud destaca por su correlación Spearman positiva.

VI-B. Variables categóricas: índice de discriminación η^2

Para evaluar la capacidad predictiva de las variables categóricas, se calculó el índice η^2 (eta-cuadrado), que mide qué proporción de la varianza total del target es explicada por cada variable categórica:

$$\eta^2 = \frac{SS_{\text{entre grupos}}}{SS_{\text{total}}}$$

Los resultados obtenidos fueron:

- **Country.of.Origin:** $\eta^2 = 0,198$ (discriminación alta) — el país de origen explica casi el 20 % de la varianza del puntaje.
- **Processing.Method:** $\eta^2 = 0,019$ (discriminación baja) — el método de procesamiento tiene un efecto limitado.
- **Color:** $\eta^2 = 0,010$ (discriminación muy baja) — el color del grano verde es prácticamente irrelevante como predictor.

Este análisis confirma que el país de origen es la variable categórica más informativa, consistente con su alta importancia en el modelo Random Forest (Sección 8). Las variables *Processing.Method* y *Color* podrían ser candidatas a eliminación en futuras iteraciones del modelo.

VI-C. PCA lineal

PCA se aplicó sobre las 48 dimensiones resultantes del preprocesamiento (5 numéricas + 43 categóricas tras one-hot encoding). La Figura 9 muestra la varianza explicada acumulada por los componentes principales. Se observa que los primeros 10 componentes concentran el 90 % de la varianza total, mientras que se requieren 15 componentes para alcanzar el 95 %. Siguiendo el criterio estándar de retener al menos el 90 % de la varianza, se seleccionaron 10 componentes, lo que representa una reducción dimensional del 79.2 % (de 48 a 10 variables).




Figura 9. Varianza explicada acumulada por PCA. 10 componentes alcanzan el 90 %.

La Tabla V compara el desempeño de los dos mejores modelos (Random Forest y Gradient Boosting) en el espacio original y en el reducido por PCA. Se observa que para Random Forest el RMSE aumenta de 2.426 a 2.532 puntos (una degradación de solo +0.105 puntos, equivalente al 4.4 % relativo), mientras que el R^2 cae de 0.187 a 0.114. Para Gradient Boosting, la degradación es más pronunciada (RMSE +0.224, R^2 0.020).

Tabla V
COMPARATIVA PCA (ORIGINAL VS 10 COMPONENTES).

Modelo	RMSE Original	R ² Original	RMSE + PCA	R ² + PCA
Random Forest	2.426	0.187	2.532	0.114
Gradient Boosting	2.439	0.179	2.663	0.020

VI-D. LDA supervisado

LDA con 1 componente discriminante (Tabla VI) degradó más el desempeño, indicando que la proyección óptima para separar especialidad vs. no especialidad no es la mejor para regresión continua.

Tabla VI
COMPARATIVA LDA SUPERVISADO (1 COMPONENTE).

Modelo	RMSE Original	R ² Original	RMSE + LDA	R ² + LDA
Random Forest	2.426	0.187	2.574	0.077
Gradient Boosting	2.439	0.179	2.544	0.100

VI-E. Kernel PCA no lineal

Kernel PCA con kernel RBF no superó a PCA lineal (Tabla VII).

Tabla VII
COMPARATIVA KERNEL PCA (ORIGINAL VS 10 COMPONENTES).

Modelo	RMSE Original	R ² Original	RMSE + KPCA	R ² + KPCA
Random Forest	2.426	0.187	2.502	0.134
Gradient Boosting	2.439	0.179	2.634	0.042

VII. IMPORTANCIA DE VARIABLES

La Figura 10 muestra las 20 variables más importantes según Random Forest, medida por reducción de impureza. Se observa que el país de origen es, con diferencia, el predictor más relevante, seguido por los defectos secundarios, la altitud y la humedad. Este análisis permite que un productor identifique qué aspectos de su cultivo tienen mayor impacto en la calidad estimada, cumpliendo con el criterio de explicabilidad del proyecto.




Figura 10. Top 20 variables más importantes según Random Forest. El país de origen es el predictor más relevante.

Este análisis permite que un productor entienda qué factores influyen en la predicción, cumpliendo con el criterio de explicabilidad del proyecto.

VIII. DISCUSIÓN Y CONCLUSIONES

VIII-A. Resumen de hallazgos

- Viabilidad moderada:** Los modelos alcanzan $R^2 \approx 0.19-0.21$, explicando el 20 % de la varianza del puntaje total. Esto es consistente con trabajos previos (UBC MDS Team 2021, AUC-ROC 0.67) y refleja que el 80 % restante depende de atributos sensoriales no disponibles en los metadatos agrícolas.
- Mejor modelo:** Random Forest (RMSE=2.426, $R^2=0.187$), seguido muy de cerca por Ridge y Gradient Boosting. Las diferencias son pequeñas, sugiriendo relaciones moderadamente lineales.
- Limitación crítica:** El error en cafés de baja calidad (>80 pts) es 2.87 veces mayor (RMSE=4.983 vs 1.735). Esto significa que, para un productor con un café en el borde de especialidad (78-82 pts), el modelo tiene una incertidumbre de ± 5 puntos, limitando su utilidad para decisiones individuales. Sin embargo, para filtrado de lotes, sigue siendo útil.
- Reducción exitosa:** PCA con 10 componentes (79.2 % compresión) degradó el RMSE solo en +0.105 puntos, demostrando que la información predictiva se concentra en pocas dimensiones.
- Clasificación útil:** El modelo alcanza 87.2 % de precisión identificando cafés de especialidad, útil para filtrado de lotes.
- Interpretabilidad:** El país de origen, defectos secundarios, altitud y humedad son los predictores más influyentes, consistente con el conocimiento agronómico.

VIII-B. Respuesta a la pregunta de investigación

¿Es posible estimar la calidad del café usando solo metadatos agrícolas? **Sí, pero con limitaciones importantes.** Es posible construir un modelo que explica el 20 % de la varianza,

con error promedio de ± 2.4 puntos. Clasifica correctamente el 87 % de los cafés de especialidad, pero tiene dificultades en cafés de baja calidad (error ± 5 puntos). Es útil como **herramienta de orientación y filtrado de lotes**, pero no reemplaza una catación oficial.

VIII-C. Trabajo futuro

Se recomienda: (1) incorporar variables climáticas y de suelo, (2) recolectar muestras balanceadas con más cafés de baja calidad, (3) implementar SHAP para explicabilidad individualizada, (4) desarrollar modelos probabilísticos que entreguen intervalos de confianza, y (5) actualizar con datos posteriores a 2018.

VIII-D. Conclusión final

Este trabajo demuestra que es posible estimar la calidad del café Arábica a partir de metadatos agrícolas, aunque con un error moderado y con dificultades en la región de baja calidad. El aporte principal no es un modelo con alta precisión (imposible sin datos sensoriales), sino un modelo **metodológicamente honesto, interpretable y útil como herramienta de orientación**. A diferencia de trabajos previos que usaron variables sensoriales o que no ofrecieron explicabilidad, este proyecto entrega un sistema que un pequeño productor puede entender y usar. El modelo no reemplaza a un catador certificado, pero democratiza el acceso a una estimación objetiva de calidad.

REFERENCIAS

- [1] M. Chen, "Coffee Quality Prediction," Kaggle, 2022.
- [2] UBC MDS Team, "Coffee Quality Predictor," GitHub, 2021.
- [3] M. K. Melewwe Thantrige, "Utilizing Machine Learning Techniques for Excellent Coffee Prediction," Tesis de maestría, National College of Ireland, 2023.
- [4] E. Kirtil, "Machine learning-driven integration of GC-MS and sensory panel data for aroma prediction in food systems," *Journal of Food Composition and Analysis*, vol. 128, 2025.
- [5] M. M. Urugo et al., "The prospects of replacing the sensory coffee quality assessment methods with objective, instrument-based approaches," *Journal of Food Engineering*, vol. 365, 2025.
- [6] I. Illari, "A scientific approach to brewing the perfect cup of joe," Zenodo, 2020.